LATIHAN KUIS

PRAKTIKUM DATA SCIENCE IF-E

Studi Kasus: Clustering Kondisi Kualitas Udara

Sebuah sistem monitoring kualitas udara memiliki data pengukuran kondisi udara yang dilakukan secara berkala. Data tersebut berisi beberapa parameter polutan dan kondisi lingkungan seperti **CO**, **Benzene**, **NOx**, **NO2**, **temperatur**, dan **kelembapan**. Untuk memahami pola kondisi udara yang memiliki karakteristik serupa, dilakukan pengelompokan menggunakan metode K-Means Clustering dan Hierarchical Clustering. Dataset yang digunakan adalah Air Quality UCI Dataset yang berisi data pengukuran kualitas udara per jam. Dataset memiliki beberapa nilai -200 yang digunakan sebagai penanda *missing value*.

Ketentuan Umum:

1. Gunakan dataset Air Quality UCI. Download pada link berikut: https://archive.ics.uci.edu/dataset/360/air%2Bquality
2. Lakukan EDA sederhana untuk memahami struktur dan kondisi dataset
3. Periksa *missing value* dan data duplikat
4. Nilai data -200 dianggap sebagai *missing value*, bukan sebagai nilai pengukuran sebenarnya
5. Gunakan fitur numerik yang relevan untuk menggambarkan kondisi kualitas udara
6. Untuk keperluan clustering, gunakan fitur:
    - CO(GT)
    - C6H6(GT)
    - NOx(GT)
    - NO2(GT)
    - T
    - RH
    - AH
7. Jangan menggunakan Date dan Time untuk fitur clustering
8. Lakukan penanganan missing value sebelum proses *clustering*
9. Lakukan standardisasi terhadap seluruh fitur yang digunakan
10. Gunakan hasil preprocessing dan standardisasi yang sama untuk K-Means dan Hierarchical Clustering
11. Tambahkan markdown penjelasan analisis untuk masing-masing blok kode maupun penjelasan secara keseluruhan
12. Kumpulkan jawaban dengan format **NIM_LatihanKuis.ipynb**

A. K-MEANS CLUSTERING

Langkah Pengerjaan:

1. Baca dataset dan tampilkan **5 data pertama**
2. Tampilkan **informasi** dataset, **ukuran** dataset, dan **statistik deskriptif**.
3. Periksa ***missing value*** dan **data duplikat**
4. Ganti nilai -200 menjadi *missing value* dan lakukan penanganan *missing value*

5. Pilih fitur yang telah ditentukan
6. Lakukan standardisasi menggunakan **StandardScaler**
7. Gunakan **Elbow Method** untuk mencoba beberapa nilai K
8. Tentukan **jumlah *cluster*** yang digunakan berdasarkan hasil Elbow Method
9. Terapkan K-Means menggunakan jumlah *cluster* yang dipilih
10. Hitung **Silhouette Score**
11. Visualisasikan hasil *clustering* menggunakan **scatter plot**
12. Buat karakteristik setiap *cluster* berdasarkan nilai rata-rata fitur
13. Jelaskan analisis karakteristik masing-masing cluster yang terbentuk

Question Analysis K-Means:

1. Berdasarkan grafik Elbow, berapa jumlah *cluster* yang dipilih? Jelaskan alasan pemilihannya!
2. Berapa nilai Silhouette Score yang diperoleh? Bagaimana interpretasi nilai tersebut terhadap kualitas *cluster*?
3. Berdasarkan rata-rata setiap fitur pada masing-masing cluster, bagaimana karakteristik kondisi kualitas udara pada setiap cluster?

B. HIERARCHICAL CLUSTERING

Langkah Pengerjaan:

1. Terapkan Agglomerative Clustering dengan:
    - Ward
    - Average
    - Complete
    - Single
2. Gunakan dataset dan hasil **preprocessing** yang sama seperti pada bagian K-Means
3. Gunakan **jumlah cluster yang sama** dengan hasil K-Means untuk perbandingan awal
4. Hitung **Silhouette Score** untuk masing-masing linkage
5. Bandingkan nilai Silhouette Score dari keempat linkage
6. Buat **dendrogram** menggunakan Ward Linkage
7. Tentukan **jumlah cluster** yang wajar berdasarkan dendrogram.
8. Buat **heatmap** fitur yang telah distandarisasi dan diurutkan berdasarkan label *cluster*
9. Buat karakteristik setiap *cluster*
10. Jelaskan analisis karakteristik cluster yang terbentuk

Question Analysis Hierarchical:

1. Linkage mana yang menghasilkan Silhouette Score paling tinggi? Jelaskan apa yang dapat ditunjukkan oleh hasil tersebut!
2. Berdasarkan dendrogram Ward, berapa jumlah *cluster* yang menurutmu paling wajar? Jelaskan dasar pemilihannya.
3. Bagaimana karakteristik kondisi kualitas udara pada cluster yang terbentuk berdasarkan hasil Hierarchical Clustering?

C. PERBANDINGAN HASIL

1. Bandingkan hasil K-Means dan Hierarchical Clustering!
2. Apakah hasil pengelompokan K-Means dan Hierarchical Clustering menghasilkan pembagian cluster yang sama? Jelaskan!
3. Bagaimana perbedaan karakteristik cluster yang terbentuk dari kedua metode?
4. Berdasarkan Silhouette Score dan visualisasi yang dihasilkan, jelaskan kualitas hasil clustering dari kedua metode!